

```
# ===== 1. Upload File CSV =====
from google.colab import files
import pandas as pd

uploaded = files.upload()
```

Show hidden output

✓ SOAL NO 4 Statistics

✓ 1. Load data

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

# Ambil nama file yang di-upload
filename = list(uploaded.keys())[0]
print("File uploaded:", filename)

# ===== 2. Baca CSV =====
df = pd.read_csv(filename, sep=';')
df.head()
```

File uploaded: dataset (1).csv

	id	order_date	user_id	product_id	quantity	
0	24	03/01/2019	62746	1	1	
1	8989	01/01/2019	53424	28	1	
2	8990	01/01/2019	53424	28	1	
3	8991	01/01/2019	53424	28	1	
4	8992	01/01/2019	53424	28	1	

✓ 2. Mengetahi bentuk awal dari dengan melakukan agregasi jumlah pembelian per customer

```
# 2. Aggregate total per customer
user_totals = df.groupby('user_id', as_index=False)['quantity'].sum().rename(cc
```

```

values = user_totals['total_quantity'].values
print("N users:", len(values))
print(user_totals.describe())

# 3. Quick diagnostics
mean = values.mean()
var = values.var(ddof=1)
print("Mean:", mean, "Variance:", var)
print("Overdispersion? (var > mean) ->", var > mean)

```

Show hidden output

Berdasarkan nilai statistik, bisa kita lihat bahwa nilai median adalah 8, artinya hampir separuh customer membeli dengan jumlah 8 qty. Sedangkan rata-rata seluruh data adalah 23. Ini berarti sebagian besar customer berada di rentang pembelian rendah. Tapi ada sebagian kecil customer yang membeli sangat banyak, sehingga “menarik” mean ke atas. Sedangkan Max pembelian sendiri juga terpaut sangat besar = 4058

Statistik	Nilai	Arti
Mean (rata-rata)	22.86	Rata-rata cust membeli 23 item.
Median (50%)	8	Setengah cust membeli 8 item atau kurang .
75%	23	75% cust beli ≤ 23 item .
Max	4058	Ada cust ekstrem yang beli ribuan item.

Ini adalah ciri distribusi yang tidak simetris dan ber-ekor panjang (heavy tail)

Lalu hasil menunjukkan $var > mean$ artinya, distribusi count normal (Poisson) tidak bisa cocok—karena Poisson mengharuskan $variance \approx mean$.


3. Cek menggunakan Histogram linear dan Histogram log scale (y) untuk melihat bentuk dasar distribusi

```

# 4. Plot histogram (linear + log scale) to inspect tail
plt.figure(figsize=(12,4))
plt.subplot(1,2,1)
plt.hist(values, bins=50)
plt.title("Histogram total_quantity (linear)")
plt.xlabel("total_quantity"); plt.ylabel("count")

plt.subplot(1,2,2)
plt.hist(values, bins=50, log=True)
plt.title("Histogram total_quantity (log y)")
plt.xlabel("total_quantity"); plt.ylabel("count")
plt.tight_layout()
plt.show()

```



- Pada gambar histogram linear, terlihat total quantity terpusat di kiri, namun grafik membentang panjang ke sumbu x dengan nilai yang sangat besar (4000++). Grafiknya tidak simetris, lebih terpusat ke kiri dengan ekor panjang ke kanan.

artinya: → Tanda distribusi right-skewed (positively skewed) → Ada heavy users (sedikit user membeli sangat banyak)

- Pada gambar histogram log scale, bentuknya jadi lebih halus, terlihat seperti garis menurun eksponensial.


artinya: → jumlah user yang beli lebih banyak turun sangat cepat → tapi tidak pernah benar-benar nol → menandakan long-tail distribution

- Ini adalah ciri-ciri data yang bukan distribusi ringan/normal, tetapi **heavy-tailed distribution**.
- Distribusi probabilitas yang memungkinkan: Lognormal Distribution atau Power Law / Pareto.

✓ 4. Identifikasi heavy tail dengan log-log CCDF

```
# Plot CCDF (Complementary CDF) untuk melihat heavy-tail
counts, bin_edges = np.histogram(values, bins=200, density=False)
cdf = np.cumsum(counts)/counts.sum()
ccdf = 1 - cdf
```

```
plt.figure(figsize=(6,4))
plt.loglog(bin_edges[1:], ccdf, marker='.', linestyle='none')
plt.title("CCDF (log-log) - cek long tail")
plt.xlabel("total_quantity"); plt.ylabel("CCDF")
plt.grid(True); plt.show()
```



Berdasarkan grafik:

- grafik menurun cukup smooth
- Tidak lurus sempurna, sedikit melengkung
- Ada derau di bagian ekor (karena data mulai jarang)
- Ekor memanjang sampai nilai besar (long tail)

Grafik log-log CCDF: membedakan jenis distribusi

a. Power Law/Pareto memiliki ciri-ciri:

- CCDF log-log terlihat garis lurus panjang
- tail tidak pernah “habis” dan tetap tebal

Sedangkan grafik tidak lurus sempurna. → Kemungkinan bukan pure power law.

b. Lognormal Distribution memiliki ciri-ciri:

- bentuknya puncak di kiri dan ekor panjang ke kanan
- ketika dibuat histogram log-scale, bentuknya jadi lebih “normal”

→ Maka distribusi probabilitas yang cocok berdasarkan ciri dan identifikasi di atas adalah **Lognormal**

✓ 5. Grafik Distribusi Lognormal

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

# pastikan kolom quantity numerik
df['quantity'] = pd.to_numeric(df['quantity'], errors='coerce').fillna(0).astype(float)

# hitung total per user
user_totals = df.groupby('user_id')['quantity'].sum().reset_index()
values = user_totals['quantity'].values

# gunakan hanya nilai > 0 untuk lognormal
pos = values[values > 0]

# --- Fit lognormal ---
shape, loc, scale = stats.lognorm.fit(pos, floc=0)

print("Lognormal params:")
print("shape:", shape)
print("loc:", loc)
print("scale:", scale)


# --- Plot histogram + lognormal ---
plt.figure(figsize=(8,4))

# histogram data user
plt.hist(pos, bins=100, density=True, alpha=0.6, label="Data")

# kurva lognormal
x = np.linspace(1, np.percentile(pos, 99), 300)
pdf = stats.lognorm.pdf(x, shape, loc=loc, scale=scale)
plt.plot(x, pdf, 'r-', linewidth=2, label="Lognormal fit")

plt.xlim(1, np.percentile(pos, 99))
plt.xlabel("total_quantity")
plt.ylabel("density")
plt.title("Lognormal Fit Only (cropped at 99th percentile)")
plt.legend()
plt.show()
```

```
Lognormal params:  
shape: 1.2930919473492162  
loc: 0  
scale: 9.213976517995512
```



Analisis distribusi menunjukkan bahwa data memiliki pola lognormal dengan ekor panjang, di mana sebagian besar SKU memiliki permintaan rendah, sementara sebagian kecil SKU menyumbang porsi terbesar dari total penjualan. Kondisi ini menandakan adanya ketimpangan kontribusi antar produk.

✓ 6. Rekomendasi bisnis

Rekomendasi bisnis yang relevan adalah:

- Prioritasi SKU ber-volume tinggi melalui penguatan stok, promosi, dan visibilitas untuk menjaga stabilitas kontribusi penjualan utama.
- Diferensiasi manajemen stok, dengan stok aman lebih besar untuk SKU high-impact dan stok efisien untuk SKU low-demand.
- Optimalisasi alokasi budget pemasaran dengan fokus pada produk yang memberikan dampak penjualan terbesar.
- Penerapan monitoring dini pada SKU yang fluktuatif untuk mendeteksi lonjakan permintaan secara cepat.

- Strategi ini membantu perusahaan memaksimalkan performa SKU penting, meningkatkan efisiensi biaya, dan mengurangi risiko kehilangan penjualan pada produk utama.

✓ SOAL NO 5 Data Visualization

✓ 1. Library

```
import matplotlib.pyplot as plt
import seaborn as sns
```

✓ 2. Analisis Cohort Retention Berdasarkan Bulan Akuisisi Pelanggan

Metrik utama: Monthly Retention Rate

Menggunakan Monthly Retention Rate sebagai metrik utama untuk memantau proporsi pelanggan unik yang kembali melakukan pembelian setiap bulan, dengan fokus pada perilaku jangka menengah yang relevan untuk strategi engagement dan retensi.

Monthly retention dipilih karena transaksi makanan tidak terjadi setiap hari dan setiap minggu secara konsisten. Monthly retention lebih stabil, mewakili pola repeat order yang realistis, dan menghasilkan cohort yang bersih, mudah dibaca, serta relevan untuk keputusan bisnis.

```
# Mengubah kolom order_date dari string menjadi tipe datetime
df['order_date'] = pd.to_datetime(df['order_date'], format='%d/%m/%Y')

#Buat kolom order_month dan cohort_month
df['order_month'] = df['order_date'].dt.to_period('M')
df['cohort_month'] = df.groupby('user_id')['order_date'].transform('min').dt.to_period('M')
##order_month: bulan transaksi saat itu → memudahkan analisis per bulan
##cohort_month: bulan pertama kali customer melakukan pembelian → menandai coh
##Dengan ini, kita bisa mengelompokkan pelanggan berdasarkan bulan mereka perta

#Hitung Cohort Index
df['cohort_index'] = (
    (df['order_month'].dt.year - df['cohort_month'].dt.year) * 12 +
    (df['order_month'].dt.month - df['cohort_month'].dt.month) + 1
)
##cohort_index = bulan ke berapa pelanggan tersebut sejak akuisisi.
```

```
##Contoh:
##Cohort bulan Januari, customer membeli lagi di Februari → cohort_index = 2
##Cohort bulan Maret, customer membeli lagi di Maret → cohort_index = 1
##Ini digunakan untuk menghitung retention bulan ke-bulan.


#Hitung jumlah customer unik per cohort per bulan
cohort_data = df.groupby(['cohort_month', 'cohort_index'])['user_id'].nunique().

# jumlah customer pertama (baseline cohort)
cohort_size = cohort_data[cohort_data['cohort_index']==1][['cohort_month', 'user_id']]
cohort_size = cohort_size.rename(columns={'user_id': 'cohort_size'})
cohort_data = cohort_data.merge(cohort_size, on='cohort_month')

# hitung retention rate
cohort_data['retention_rate'] = cohort_data['user_id'] / cohort_data['cohort_size']

# pivot untuk heatmap
cohort_pivot = cohort_data.pivot(index='cohort_month',
                                  columns='cohort_index',
                                  values='retention_rate')

# plot heatmap
plt.figure(figsize=(10,6))
sns.heatmap(cohort_pivot, annot=True, fmt=".0%", cmap="Blues")
plt.title("Cohort Retention Heatmap")
plt.ylabel("Acquisition (Cohort) Month")
plt.xlabel("Cohort Index (Months After Acquisition)")
plt.show()
```

3. Detail Heatmap

Heatmap ini menunjukkan:

- baris = cohort, yaitu bulan pertama customer melakukan order
- kolom = bulan ke-berapa sejak customer pertama kali beli
- angka di dalam tabel = persentase customer yang masih melakukan pembelian di bulan tersebut

4. Analisis Heatmap

Retention Month+1 berada di 35–46%, artinya setengah customer hilang setelah bulan pertama.

Pada bulan ke-2 hingga ke-4 terlihat penurunan tajam, yang menandakan periode kritis terjadinya churn.

Sekitar 10–15% customer bertahan hingga bulan ke-6, membentuk kelompok pengguna loyal.

Distribusi order membentuk pola long-tail: mayoritas customer hanya order 1–2 kali, dan hanya sedikit customer yang membuat banyak transaksi.

5. Rekomendasi Bisnis

- Pengalaman pertama cust belum cukup untuk membuat cust melakukan repeat